



# Inteligencia Artificial para profesionales TIC

Otros conceptos fundamentales del ML



- 01.** Aprendizaje no supervisado
- 02.** Detección de anomalías
- 03.** Aprendizaje por refuerzo
- 04.** Sistemas multiagente (MAS)
- 05.** Una visión global del aprendizaje automático
- 06.** Pros y contras del aprendizaje automático
- 07.** Roles en ciencia de datos, IA y ML



# 1. Aprendizaje no supervisado

## Solo datos, solo datos

¿Qué podemos hacer si solo tenemos datos? (p. ej., pacientes con solo síntomas). Principalmente, analizarlo y encontrar patrones, clústeres, etc.

No conocemos la clase ni el valor de los datos de entrenamiento.

No tenemos conocimiento de cómo se clasifican los datos y nuestro objetivo es buscar la estructura oculta de los datos.

En el aprendizaje no supervisado (siendo la técnica más popular la que llamamos clustering), no podemos usar la técnica anterior (no tenemos una verdad fundamental) -> no podemos evaluar con la 'verdad', no tenemos etiquetas ni valores en nuestro conjunto de datos de entrada.

No tenemos conocimiento de cómo se clasifican los datos y nuestro objetivo es buscar la estructura oculta de los datos.

El resultado puede ser solo una predicción de a qué clúster o grupo (si podemos encontrarlos) pertenece nuestra entrada.



# 1. Aprendizaje no supervisado

## Aprendizaje autosupervisado

En términos simples, **self-supervised learning** es un tipo de aprendizaje automático en el que un modelo aprende a hacer predicciones mediante el uso de partes de los datos de entrada como entrada y destino (o "etiqueta"). Esencialmente, el modelo aprende a generar sus propias señales de entrenamiento o señales de supervisión a partir de los propios datos, sin depender de etiquetas explícitas generadas por humanos.

El aprendizaje no supervisado, por otro lado, es una categoría más general de aprendizaje automático en la que los modelos aprenden patrones, estructuras o relaciones dentro de los datos sin ningún ejemplo etiquetado. El objetivo principal del aprendizaje no supervisado suele ser descubrir patrones subyacentes o agrupaciones en los datos, en lugar de hacer predicciones.

El aprendizaje autosupervisado se tratará cuando hablemos de la IA generativa y la revolución del Gran Modelo de Lenguaje (con arquitecturas NN como RNN y el transformer)



## 2. Detección de anomalías

### Cuando las anomalías no se deben a datos incorrectos

Una anomalía es un elemento significativamente diferente al resto de datos observados.

Es un elemento "sospechoso".

Es posible utilizar muchas técnicas diferentes para la detección de anomalías, incluso en las familias de técnicas supervisadas y no supervisadas.

Las técnicas no supervisadas intentan ver si un valor es muy diferente (distancia a los diferentes grupos de clases generadas automáticamente).

Las técnicas supervisadas intentan etiquetar los ejemplos como "normales" y "no normales" y crean un modelo clasificador supervisado a partir de eso.

Aplicaciones: fraude, detección de intrusos, defectos estructurales, problemas médicos, etc..



## 2. Detección de anomalías

### Diferencias entre valores atípicos y anomalías

**Outlier detection** se refiere al proceso de identificar puntos de datos u observaciones que se desvían significativamente de los patrones generales o la distribución del conjunto de datos. Los valores atípicos pueden ser el resultado de errores de medición, errores de entrada de datos o eventos poco frecuentes. El objetivo principal de la detección de valores atípicos es quitarlos o corregirlos para mejorar la calidad de los datos o el rendimiento de un modelo de aprendizaje automático.

**Detección de anomalías**, por otro lado, es el proceso de identificar patrones o eventos que son inusuales, inesperados o inconsistentes con el comportamiento normal de un sistema o proceso. Las anomalías pueden ser indicativas de problemas subyacentes, como fraude, fallos en los equipos o infracciones de seguridad. El objetivo principal de la detección de anomalías es descubrir estos patrones o eventos inusuales y alertar a las partes interesadas relevantes, para que puedan tomar las medidas adecuadas para abordar los problemas subyacentes.




# 3. Aprendizaje por refuerzo

## Aprender de las experiencias, no de los datos

El aprendizaje por refuerzo es un subcampo del aprendizaje automático en el que la máquina "vive" en un entorno y es capaz de percibir el estado de ese entorno como un vector de características. La máquina puede ejecutar acciones en todos los estados. Diferentes acciones traen diferentes recompensas y también podrían mover la máquina a otro estado del entorno. El objetivo de un algoritmo de aprendizaje por refuerzo es aprender una política.

Una política es una función (similar al modelo de aprendizaje supervisado) que toma el vector de características de un estado como entrada y genera una acción óptima para ejecutar en ese estado. La acción es óptima si maximiza la recompensa media esperada.

El aprendizaje por refuerzo resuelve un tipo particular de problema en el que la toma de decisiones es secuencial y el objetivo es a largo plazo, como los juegos, la robótica, la gestión de recursos o la logística.





## 4. Multi-Agent Systems (MAS)

### De un solo agente a MAS

**Multi-Agent Systems (MAS)** se refiere a un marco computacional en el que múltiples agentes autónomos interactúan entre sí y con su entorno para lograr objetivos individuales o colectivos. Estos agentes son entidades inteligentes, a menudo diseñadas con un grado de adaptabilidad, capacidad de aprendizaje y poder de decisión. Pueden representar humanos, robots, componentes de software o cualquier otra entidad que pueda percibir, razonar y actuar dentro de un contexto determinado.

Los sistemas multiagente se utilizan comúnmente para modelar y resolver problemas complejos que involucran múltiples componentes que interactúan. Son especialmente útiles en situaciones en las que el control centralizado no es factible o eficiente, y en las que los componentes deben funcionar de forma autónoma y colaborativa para lograr los resultados deseados.





# 4. Multi-Agent Systems (MAS)

## De un solo agente a MAS

Las características clave de los sistemas multiagente incluyen::

**Autonomía:** Los agentes de un MAS tienen la capacidad de tomar decisiones y realizar acciones de forma independiente, sin ser controlados explícitamente por una autoridad centralizada.

**Visión y conocimiento local:** Por lo general, cada agente tiene una perspectiva local y un conocimiento limitado sobre el entorno o el estado de otros agentes. Se apoyan en la comunicación y la interacción con otros agentes para compartir información y coordinar sus acciones.

**Control descentralizado:** En un MAS, el control se distribuye entre los agentes, lo que permite soluciones más robustas y adaptativas que pueden manejar mejor las incertidumbres, los cambios y las fallas en el entorno.

**Cooperación y coordinación:** Los agentes de un MAS a menudo necesitan cooperar y coordinar sus acciones para lograr objetivos comunes o para resolver problemas complejos que no pueden ser abordados por un solo agente.

**Comportamiento emergente:** Los sistemas multiagente pueden exhibir comportamientos complejos y globales que emergen de las interacciones locales y las decisiones de los agentes individuales, incluso si estos comportamientos no se programaron explícitamente en el sistema.



# 4. Multi-Agent Systems (MAS)

## De un solo agente a MAS

Las aplicaciones de los sistemas multiagente se pueden encontrar en varios dominios, como la robótica, el transporte, la logística, las redes inteligentes, la computación distribuida, los juegos y muchos más.

El estudio del MAS involucra temas como las arquitecturas de los agentes, los protocolos de comunicación, las estrategias de negociación y cooperación, los mecanismos de aprendizaje y los métodos para el manejo de conflictos y la coordinación entre agentes.



# 4. Multi-Agent Systems (MAS)

## De un solo agente a MAS

El aprendizaje por refuerzo (RL) y los modelos de lenguaje están ampliando las capacidades de los sistemas multiagente (MAS) de varias maneras:

**Aprendizaje por refuerzo multiagente (MARL):** Las técnicas de aprendizaje por refuerzo se han extendido al entorno multiagente, lo que permite a los agentes aprender y adaptar sus estrategias mientras interactúan con otros agentes del entorno.

**Modelar comportamientos sociales y similares a los humanos:** Los modelos lingüísticos avanzados y las técnicas de aprendizaje por refuerzo permiten a los agentes aprender y modelar comportamientos sociales y humanos, como la cooperación, la negociación y la empatía. Esto puede mejorar la capacidad de los agentes de un MAS para interactuar con los humanos y operar en entornos que involucren a participantes humanos.

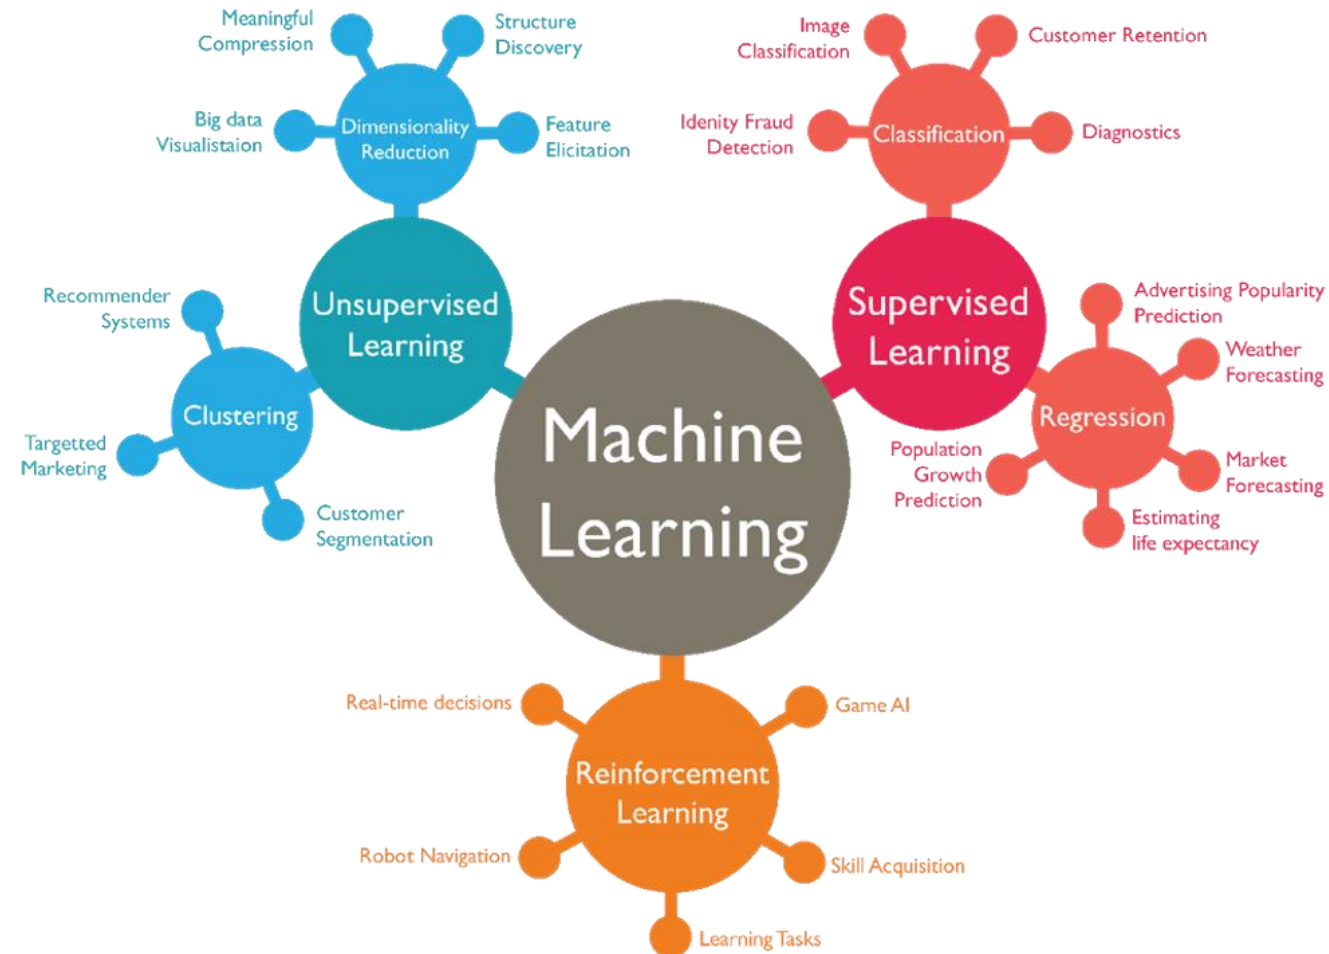
Al incorporar el aprendizaje profundo, el aprendizaje por refuerzo y los modelos lingüísticos en los sistemas multiagente, los investigadores y profesionales pueden desarrollar sistemas más potentes, adaptables e inteligentes que puedan abordar mejor los desafíos y las complejidades de los problemas del mundo real en varios dominios.

**Sugerencia:** AutoGPT



# 5. Visión global del aprendizaje automático

## ML en general





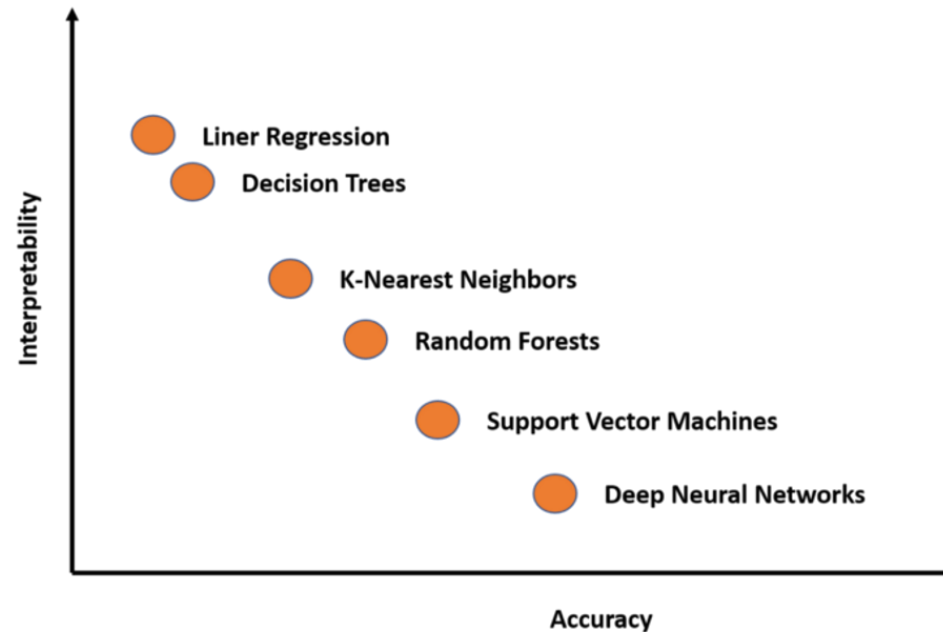
# 6. Pros y cons del aprendizaje automático

## Trade-offs

La interpretabilidad se refiere a lo fácil o complejo que es saber/explicar por qué un modelo ha hecho una predicción a partir de una entrada.

Tenemos modelos de ML muy transparentes y otros que son 'cajas negras' completas.

Desafortunadamente, tenemos una disyuntiva entre la interpretabilidad y la precisión.

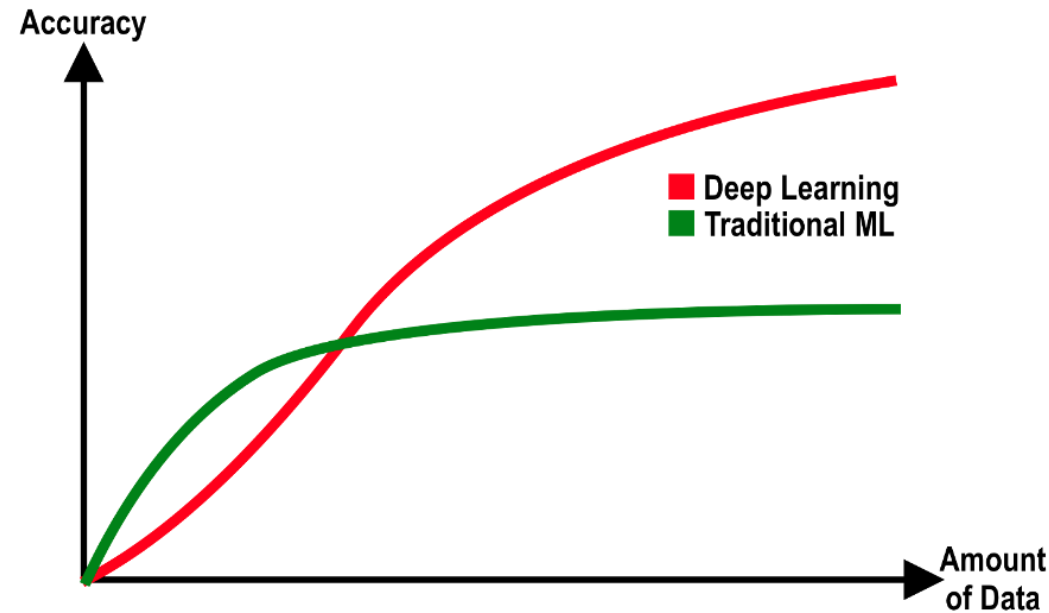




# 6. Pros and Cons del ML

## Trade-offs

Algunas técnicas de ML mejoran con la cantidad de datos (deep learning), lo que nos obliga a tener un gran conjunto de datos  
Otras técnicas pueden obtener muy buenos resultados, e incluso ser más simples/rápidas, con pequeños conjuntos de datos.





# 7. Roles en ciencia de datos, IA y ML

## En un mundo perfecto

- **Analista** de negocios (requisitos del cliente)
- **Responsable de proyecto** (metodologías ágiles, metodologías DS, gestión de equipos..)
- **Arquitecto de datos** (infraestructura de datos, computación en la nube, escalabilidad, tolerancia a fallos...)
- **Científico de datos**: Utiliza diversas técnicas de estadística y aprendizaje automático para procesar y analizar datos. A menudo es responsable de crear modelos para probar lo que se puede aprender de alguna fuente de datos, aunque a menudo a nivel de prototipo en lugar de producción.
- **Ingeniero de datos**: Desarrolla un conjunto robusto y escalable de herramientas/plataformas de procesamiento de datos. Debe sentirse cómodo con la organización de bases de datos SQL/NoSQL y la creación o el mantenimiento de canalizaciones ETL.
- **Ingeniero de aprendizaje automático (ML)**: a menudo responsable tanto de entrenar modelos como de producirlos. Requiere estar familiarizado con algún marco de ML de alto nivel y también debe sentirse cómodo creando canalizaciones escalables de entrenamiento, inferencia e implementación para modelos.
- **Científico de aprendizaje automático (ML)**: Trabaja en investigación de vanguardia. Por lo general, responsable de explorar nuevas ideas que puedan publicarse en conferencias académicas. A menudo, solo necesita crear prototipos de nuevos modelos de última generación antes de entregarlos a los ingenieros de ML para que los pongan en producción.

